

«Επιχειρηματική Αναλυτική και Τεχνολογίες Εξατομίκευσης»

Σκοπός Εργασίας

Σκοπός της εργασίας είναι η ανάλυση δεδομένων με στόχο την εξαγωγή χρήσιμων συμπερασμάτων για την υποστήριξη επιχειρηματικών αποφάσεων (επιχειρηματική αναλυτική). Τα δεδομένα αφορούν στοιχεία ζήτησης καταναλωτικών προϊόντων από κατάστημα supermarket (point-of-sales data, POS). Παρακάτω ακολουθούν η περιγραφή των δεδομένων καθώς και τα βασικά ερωτήματα που καλείστε να απαντήσετε.

Περιγραφή Δεδομένων

[Α]. Στο πρώτο φύλλο (“POS Data”) του Excel, υπάρχουν Point Of Sales (POS) data, τα οποία αναφέρονται στις συναλλαγές που πραγματοποιήθηκαν στο ταμείο ενός σουπερμάρκετ. Τα πεδία των συναλλαγών περιέχουν τις εξής πληροφορίες:

Basket_ID: Κάθε Basket_ID αναφέρεται σε μια απόδειξη.

Date: Το πεδίο αναφέρεται στην ημερομηνία που πραγματοποιήθηκε το transaction (dd/mm/yyyy).

Barcode: Αναφέρεται στον μοναδικό αριθμό προϊόντος.

Quantity: Αναφέρεται στον αριθμό των τεμαχίων που αγοράστηκαν από το συγκεκριμένο barcode.

Value: Αναφέρεται στην αξία αγορών από το συγκεκριμένο barcode.

LoyaltyCard_ID: Αναφέρεται στον μοναδικό αριθμό της κάρτας πιστότητας του πελάτη. Αν λαμβάνει τιμή=NULL, τότε ο πελάτης δεν χρησιμοποίησε στη συγκεκριμένη συναλλαγή την κάρτα του.

Ακολουθεί παράδειγμα για την κατανόηση των παραπάνω πεδίων που περιέχονται στα POS Data. Στον Πίνακα 1 το Basket_ID, δηλώνει ότι έχουμε δεδομένα από αποδείξεις 4^{ων} διαφορετικών αγορών. Τα δύο πρώτα καλάθια αγορών περιέχουν από δύο μοναδικά προϊόντα το καθένα, ενώ τα υπόλοιπα έχουν από ένα. Στη στήλη “Quantity” όλα τα προϊόντα που έχουν αγοραστεί αφορούν σε ένα μόνο τεμάχιο, εκτός από το τελευταίο που αφορά σε δύο τεμάχια. Η στήλη “Value” δείχνει την συνολική αξία όλων των τεμαχίων του συγκεκριμένου barcode.

Basket_ID	Date	Barcode	Quantity	Value	LoyaltyCard_ID
C28002183B2D20181116	11/16/2018	5204416014100	1	10	28002183
C28002183B2D20181116	11/16/2018	5201228231336	1	0.33	28002183
C28098497B2D20190508	5/8/2019	5012501081155	1	2.36	28098497
C28098497B2D20190508	5/8/2019	5201004021328	1	1.4	28098497
C28325357B2D20181203	12/3/2018	5201395600812	1	2.74	28325357
C28325421B2D20190530	5/30/2019	5202178080234	2	2.16	28325421

Πίνακας 1: Παράδειγμα POS δεδομένων

TIP1: Προσοχή σε ενδεχόμενες αρνητικές τιμές στις στήλες “Quantity” και “Value”


TIP2: Προσοχή σε μη ακέραιες τιμές στη στήλη “Quantity”

TIP3: Κάθε έγκυρο barcode περιέχεται στο φύλλο “Hierarchy Categories & Barcodes”

[B]. Στο δεύτερο φύλλο (“Loyalty”) του Excel περιέχεται πληροφορία του πελάτη σχετικά με την κατάσταση του νοικοκυριού του. Η πληροφορία “Status” λαμβάνει τιμές “Family” αν είναι οικογένεια, “Man” αν είναι άντρας, “Woman” αν είναι γυναίκα και “na” αν ο κάτοχος δεν έχει δηλώσει το συγκεκριμένο πεδίο.

TIP4: (Information Quality) τα στοιχεία του “status” είναι κατά δήλωση, επομένως μπορεί να μην συμβαδίζουν με insights τα οποία μπορεί να εξαχθούν κατά την ανάλυση.

[Γ]. Στο τρίτο φύλλο (“Hierarchy Categories & Barcodes”) του Excel περιέχονται οι κωδικοί των προϊόντων (barcodes), μαζί με το δέντρο της ιεραρχίας των κατηγοριών στις οποίες ανήκουν. Κάθε εγγραφή περιέχει το barcode και τα τρία επίπεδα κατηγοριών που εμπίπτει το συγκεκριμένο. Null τιμές στα πεδία των επιμέρους κατηγοριών σημαίνει ότι η συγκεκριμένη κατηγορία δεν σπάει σε άλλες επιμέρους, οπότε σταματάει στο προηγούμενο επίπεδο.



Εικόνα 1: Επίπεδα δέντρου ιεραρχίας κατηγοριών

TIP5: Το δέντρο ιεραρχίας των προϊόντων έχει φτιαχτεί για να εξυπηρετεί διάφορους σκοπούς και εργασίες του λιανέμπορου, και όχι πάντα τους σκοπούς της ανάλυσης.

Ερωτήματα

[1]. Basket segmentation. Ποιες ομάδες καλαθιών μπορείτε να αναγνωρίσετε στα δεδομένα οι οποίες να εξηγούν την αγοραστική συμπεριφορά, δηλαδή το είδος της επίσκεψης που έκανε ένας πελάτης;

Εδώ καλείστε αρχικά να επιλέξετε μετρικές και διαστάσεις που θα χρησιμοποιήσετε για να τμηματοποιήσετε τα καλάθια. Έπειτα καλείστε να παρουσιάσετε τα segments καλαθιών τα οποία εξαγάγατε.

[2]. Customer segmentation. Ποιες ομάδες πελατών μπορείτε να αναγνωρίσετε στα δεδομένα;

Εδώ καλείστε αρχικά να επιλέξετε μετρικές και διαστάσεις που θα χρησιμοποιήσετε για να τμηματοποιήσετε τους πελάτες. Έπειτα καλείστε να παρουσιάσετε τα segments πελατών τα οποία εξαγάγατε. (Σημείωση: στοιχεία από το *basket segmentation* μπορούν να χρησιμοποιηθούν ως *input* σε αυτή την ανάλυση)

TIP6: Δεν χρησιμοποιούμε ως διάσταση στην ανάλυση διαστάσεις που έχουν προβλήματα αναφορικά με την ποιότητα των δεδομένων

[3]. Ανοιχτή ερώτηση. Απαντήστε οποιαδήποτε άλλη ανοιχτή ερώτηση θέλετε με χρήση των δεδομένων.

Αξιολόγηση

Η εργασία θα παραδοθεί και θα εξεταστεί σε μορφή **παρουσίασης**.

Δώστε έμφαση στην **παρουσίαση** και **ερμηνεία** των **αποτελεσμάτων**.

Όλα τα ερωτήματα θα πρέπει να απαντηθούν ομαδικά.

Ενδεικτικά Εργαλεία

1. RapidMiner Studio

- Αιτηθείτε την ακαδημαϊκή έκδοση του προγράμματος με την χρήση του aueb email σας:
<https://rapidminer.com/educational-program/>

2. Microsoft SQL Server Management Studio (SSMS)

- Product Version”: Business Intelligence ή Standard

3. Data Mining Client for Excel (SQL Server Data Mining Add-ins)

- Μπορείτε να το κατεβάσετε free από το site της Microsoft. Προσοχή πρέπει να βρείτε την έκδοση που ταιριάζει στο SSMS που έχετε κατεβάσει και στο Microsoft Office που έχετε εγκατεστημένο στο pc σας. Πχ:
- <https://www.microsoft.com/en-us/download/details.aspx?id=29061>